Universidad de Las Américas

Facultad de Ingeniería y Ciencias Aplicadas

Maestría en Inteligencia Artificial Aplicada

Asistente inteligente local para la consulta del inventario tecnológico de SynerGy mediante lenguaje natural, arquitectura de generación aumentada por recuperación RAG, modelos ejecutados en Ollama y búsqueda vectorial en SQL Server

Galo Andrés Estrella
Wilian Pepinos

Avance consolidado del proyecto y documento final

Corte técnico 29 de octubre de 2026
Entrega 30 de octubre de 2026

Quito, Ecuador
Octubre de 2026

Contenido

Resumen 1

Abstract 2

1 Introducción 3

2 Análisis de posibles soluciones 5

3 Objetivos 6

4 Alcance y restricciones 7

5 Planificación y costos 8

6 Estudios y metodología 9

7 Desarrollo del proyecto 10

8 Conclusiones y recomendaciones 20

9 Trabajo futuro 21

10 Referencias bibliográficas 22

11 Anexos técnicos 23

Anexo B Interfaz de consultas 24

Anexo C Demostración con datos ficticios 25

Anexo D Escenarios adversariales declarados 26

Anexo E Evidencias y lectura del repositorio 27

Resumen

El inventario tecnológico de SynerGy requiere respuestas oportunas sobre equipos, disponibilidad y custodios, junto con la consulta de información histórica registrada en actas. El proyecto desarrolla un asistente local en español que combina consultas estructuradas y recuperación de contexto mediante embeddings almacenados en SQL Server 2025. El artefacto utiliza ASP.NET Core, Ollama, qwen2.5-coder:7b y nomic-embed-text, con validación externa de T-SQL mediante ScriptDom.

La versión consolidada distingue tres rutas: consultas controladas para listas y cantidades habituales; generación de SQL con el modelo, apoyada por un catálogo semántico; y búsqueda vectorial del texto de actas. El directorio autorizado permite resolver nombres sin inventar correos y solicita aclaración ante ambigüedad. Los conteos se ejecutan sobre el inventario actual; las actas no se utilizan como sustituto del stock vigente.

La evidencia histórica comprende 270 generaciones: la exactitud por componentes pasó de 55,6 % en el baseline a 96,7 % en la configuración ajustada. Es un indicador aproximado del texto SQL y no una medida de exactitud de ejecución. En la consolidación se superaron 95 de 95 pruebas automáticas, incluidos 30 escenarios SQL adversariales, y 8 de 8 casos funcionales seleccionados. Se efectuó además una regresión de nueve generaciones sobre tres preguntas del conjunto de desarrollo. Estos resultados no sustituyen una evaluación independiente de 120 preguntas ni pruebas con usuarios.

Se entrega código modular, dependencias bloqueadas, instrucciones de ejecución, una demo visual explícitamente sintética, datos ficticios para un despliegue SQL y un repositorio versionado. El modelo se utiliza con pesos preentrenados; no se realizó entrenamiento ni ajuste fino. Continúan pendientes la evaluación ampliada, la relevancia del recuperador, la medición del proceso humano y los controles de identidad para un despliegue institucional.

Palabras clave: RAG, text-to-SQL, SQL Server, embeddings, Ollama, inventario tecnológico, validación de software.

Abstract

SynerGy needs timely answers about IT equipment, availability and custodians, as well as access to historical information recorded in handover records. This project develops a local Spanish-language assistant that combines structured queries and embedding-based retrieval in SQL Server 2025. The artifact uses ASP.NET Core, Ollama, qwen2.5-coder:7b and nomic-embed-text, with external T-SQL validation through ScriptDom.

The consolidated prototype separates controlled queries for common lists and counts, model-generated SQL supported by a semantic catalog, and vector search over handover record text. An authorized directory resolves names to institutional addresses and requests clarification when multiple matches exist. Inventory counts are computed from the current inventory view; historical records are not treated as current stock.

The historical experiment includes 270 generations, with component-based accuracy increasing from 55.6% to 96.7%. This proxy measures expected SQL patterns rather than execution correctness. The consolidated version passed 95 automated tests, including 30 adversarial SQL scenarios, and 8 selected functional checks. A nine-generation regression test covered three development questions. These results do not establish performance on an independent 120-question set or prove improvements in the human workflow.

The delivery includes modular code, locked dependencies, execution instructions, an explicitly synthetic visual demo, fictitious SQL data and a versioned repository. The language model retains its pretrained weights; no fine-tuning was performed. Remaining work includes broader evaluation, retrieval relevance assessment, user studies and institutional identity and authorization controls.

Keywords: retrieval-augmented generation, text-to-SQL, SQL Server, embeddings, local language models, IT inventory.

1 Introducción

La información del inventario es útil cuando una persona puede formular una necesidad concreta y recibir una respuesta verificable. Preguntas como cuántas computadoras portátiles están disponibles o qué equipos tiene un colaborador combinan lenguaje de negocio, códigos de estado y conocimiento del esquema. Los reportes estáticos cubren solo parte de esas necesidades y obligan a escalar otras consultas al personal técnico.

Los modelos de lenguaje facilitan la interpretación de preguntas, pero sus respuestas deben vincularse a fuentes autorizadas. En text-to-SQL, una sentencia plausible puede tener errores de dialecto, filtros incompletos o agregaciones equivocadas. La propuesta incorpora conocimiento del dominio, recuperación de contexto y controles externos al modelo, de modo que la ejecución no dependa únicamente de instrucciones en el prompt.

El proyecto se ubica en el área de Tecnología de SynerGy y aborda el inventario de activos informáticos. Su unidad de aplicación son las consultas sobre equipos y la búsqueda de texto histórico en actas. No evalúa las actividades financieras de la organización ni incorpora decisiones sobre personas. La información personal del custodio se utiliza únicamente para identificar la relación con los activos solicitados.

Este avance consolida el artefacto técnico y distingue lo implementado de las metas de investigación aún abiertas. Se conserva la estructura del documento final: problema, alternativas, objetivos, alcance, planificación, estudios, desarrollo, resultados, ética, conclusiones y anexos. Las cifras históricas, las verificaciones actuales y las demostraciones sintéticas se presentan por separado para evitar conclusiones que excedan la evidencia.

1.1 Problema y línea base

La dificultad principal es la traducción entre expresiones del usuario y el significado real de los datos. NombreModelo identifica el modelo del fabricante y no el tipo de equipo. Las categorías están fragmentadas: una laptop puede estar clasificada como LAPTOP o como COMPUTADOR con descripción Laptop. Un filtro que busque la palabra laptop en cualquier descripción incluye cargadores, bases y soportes. Asimismo, los kits teclado-mouse requieren una regla explícita de conteo.

Se confirmó con el usuario que cada registro de kit teclado-mouse cuenta como un mouse. Esta decisión se incorporó a las reglas controladas y al contexto del generador. La corrección resuelve un problema de calidad semántica: una consulta válida en SQL no garantiza que la categoría seleccionada represente el concepto del negocio.

Indicador	Instrumento previsto	Meta del proyecto	Estado al corte
Tiempo de atención	Registro de 30 solicitudes reales	Reducción de al menos 40 %	No medido en el proceso humano
Resolución inicial	Consulta resuelta sin escalamiento	70 % del catálogo	Pendiente de usuarios
Exactitud de respuesta	120 preguntas con referencia aprobada	Al menos 85 %	Solo evidencia preliminar
Trazabilidad	Fuente y ejecución identificables	100 % de respuestas evaluadas	Evidencia visible; auditoría por usuario pendiente
Seguridad SQL	30 cargas adversariales declaradas	Bloquear las 30	Conjunto automatizado superado

Tabla 1. Indicadores y estado. La exactitud del LLM no es una línea base del tiempo de atención humano. Las metas organizacionales requieren medición propia.

La concentración del conocimiento en el equipo técnico y la ausencia de tiempos registrados motivan el estudio, pero no permiten estimar ahorros reales. Se propone registrar categoría, inicio, fin, respuesta validada y necesidad de escalamiento, con identificadores ficticios y sin copiar información personal al instrumento de evaluación.

2 Análisis de posibles soluciones

Se compararon un asistente local con Ollama y SQL Server y una alternativa administrada con Microsoft Copilot Studio. La primera favorece control del procesamiento y reproducción del experimento; la segunda representa una integración posible con el ecosistema corporativo. La matriz utiliza una escala de 1 a 5 y ponderaciones del diseño inicial, inspiradas en atributos de calidad de sistemas de IA. No constituye una certificación de conformidad ni una prueba empírica de ambas plataformas.

Criterio	Peso	Local	Administrada
Robustez y corrección funcional	20 %	4,3	4,1
Privacidad y control del dato	20 %	5,0	4,0
Explicabilidad y trazabilidad	15 %	4,4	4,2
Integración con el ecosistema	15 %	3,8	5,0
Mantenibilidad	10 %	3,8	4,6
Reproducibilidad	10 %	4,8	3,6
Viabilidad de implementación	10 %	3,9	4,7
Puntaje ponderado	100 %	4,34	4,29

Tabla 2. Matriz de selección del diseño inicial. Fuente: valoración del equipo en la propuesta. La diferencia estrecha no demuestra superioridad estadística.

Se implementó la alternativa local. La arquitectura permite inspeccionar el esquema, el contexto recuperado, el SQL propuesto y su validación. La alternativa administrada permanece como comparación de diseño; no se presenta como un prototipo construido ni se atribuyen resultados experimentales que no fueron medidos.

El beneficio esperado es facilitar el acceso a información verificable y reducir consultas repetitivas al personal técnico. El impacto depende de la calidad de los datos y de un uso limitado a la gestión de activos. La posibilidad de consultar custodios exige controles de identidad, minimización y supervisión, incluso cuando la inferencia ocurre localmente.

3 Objetivos

3.1 Objetivo general

Desarrollar un asistente inteligente local para consultar el inventario tecnológico de SynerGy en lenguaje natural, mediante recuperación de contexto, modelos ejecutados en Ollama, consultas controladas y búsqueda vectorial en SQL Server, con respuestas verificables y controles que permitan evaluar exactitud, trazabilidad, seguridad y tiempo de respuesta.

3.2 Objetivos específicos

OE1. Analizar el proceso de consulta, consolidar un catálogo de necesidades y medir una línea base de al menos 30 solicitudes reales antes de estimar beneficios organizacionales.

OE2. Preparar las fuentes autorizadas, el diccionario semántico y un conjunto de 120 preguntas de referencia, con controles de calidad y seudonimización.

OE3. Implementar recuperación de contexto e indexación vectorial en SQL Server y evaluar relevancia y cobertura de los fragmentos recuperados.

OE4. Implementar la traducción a SQL y los controles externos, restringir fuentes y comprobar el bloqueo de los 30 escenarios adversariales declarados.

OE5. Evaluar el asistente con referencias aprobadas y usuarios, contrastando exactitud, fidelidad, trazabilidad y latencia; documentar resultados y limitaciones.

Las metas finales de exactitud de al menos 85 %, fidelidad de al menos 0,90, trazabilidad completa y p95 de hasta ocho segundos se mantienen como criterios de evaluación. El corte actual no demuestra su cumplimiento global. La implementación técnica está consolidada para pruebas locales; la evaluación ampliada y del proceso humano permanece abierta.

4 Alcance y restricciones

Fuente	Uso implementado	Límite
VistaEquipo	Listas, filtros y agregaciones de activos	Única fuente libre permitida al SQL generado
VistaColaboradorInv	Resolución parametrizada de nombre y correo	Solo proyección necesaria; no se consulta desde el LLM
Acta y TipoActa	Texto, tipo, fecha y referencia de actas activas	Búsqueda histórica, separada del inventario vigente
ActaDetalle	Contexto del esquema histórico	No se usa para contar el stock actual
Catálogo auxiliar	Embeddings de contexto y actas	Versiones independientes y credencial de indexación

Tabla 3. Fuentes de la versión consolidada. No se incluye recuperación de archivos PDF/DOCX externos ni búsqueda en veinte manuales.

La aplicación ejecuta consultas del inventario y búsquedas del texto que ya reside en SQL. El cuerpo de las actas es una fuente textual estructurada por registro; no requiere descargar documentos binarios. Los resultados del buscador semántico son coincidencias top-K y no un censo de documentos.

Las operaciones implementadas no modifican activos, asignaciones ni actas. La indexación escribe únicamente en la tabla auxiliar; la restricción por custodio utiliza una tabla temporal por conexión. Los permisos mínimos deben ser aplicados y comprobados por el administrador. La aplicación local aún no implementa autenticación ni autorización por usuario.

El prototipo depende de SQL Server 2025, conectividad a la fuente autorizada y modelos locales disponibles. La búsqueda de actas admite tema, tipo explícito y custodio resuelto; no implementa filtros exactos por número o fecha. Las listas muestran hasta 100 filas e indican truncamiento. La inferencia en CPU puede superar un minuto.

5 Planificación y costos

La planificación original comprende veinte semanas, del 15 de septiembre de 2026 al 30 de enero de 2027. El prototipo y su consolidación técnica se adelantaron respecto a algunas fases previstas. El estado al corte no debe confundirse con el cierre de la evaluación organizacional.

Fase	Período previsto	Estado resumido
Planificación y acceso	Semana 1	Entorno y conexiones autorizadas disponibles
Diagnóstico	Semanas 2 a 4	Análisis del problema; línea base humana pendiente
Base de conocimiento	Semanas 5 a 7	Catálogos, actas y demo; gold set ampliado pendiente
Recuperación	Semanas 8 a 11	Implementada; relevancia pendiente de etiquetado
SQL y seguridad	Semanas 12 a 14	Módulo y conjunto adversarial implementados
Integración	Semanas 15 a 16	API e interfaz local; empaquetado documentado
Evaluación final	Semanas 17 a 18	Pruebas preliminares; usuarios y 120 preguntas pendientes
Documento y defensa	Semanas 19 a 20	Avance consolidado de esta entrega

5.1 Estimación referencial

Rubro	Supuesto	USD
Trabajo del equipo	2 personas x 20 semanas x 15 h = 600 h; USD 12/h	7 200
Hardware	Depreciación proporcional estimada	300
Conectividad y energía	Estimación del período	150
Subtotal		7 650
Contingencia	10 %	765
Total estimado		8 415

Tablas 4 y 5. Plan y presupuesto referencial. Se corrige la multiplicación de horas del documento previo: 600, no 400. Los valores son supuestos de planificación; no representan gastos ejecutados ni ahorro medido.

6 Estudios y metodología

El trabajo se organiza como investigación aplicada de diseño de un artefacto, con comprensión del problema, construcción y evaluación iterativa (Peffers et al., 2007). La secuencia se apoya en un ciclo CRISP-DM adaptado: comprensión del negocio y de los datos, preparación del contexto, configuración de modelos, evaluación y documentación (Chapman et al., 2000).

RAG combina un generador con información recuperada de una memoria externa (Lewis et al., 2020). En esta implementación, el contexto del inventario se obtiene desde un catálogo semántico y el texto de las actas se recupera por distancia coseno. La generación de conteos y agregaciones exige ejecutar SQL sobre la fuente completa; recuperar solo filas cercanas no permite calcular correctamente el total.

La literatura de text-to-SQL recomienda controlar el lenguaje generado y evaluar su resultado. PICARD muestra la utilidad de restricciones sintácticas (Scholak et al., 2021), mientras que los trabajos de evaluación de SQL distinguen coincidencia de texto y exactitud de ejecución (Yu et al., 2018). El proyecto aplica un analizador externo después de generar la consulta, en lugar de considerar suficiente una instrucción en el prompt.

La evaluación de recuperación y generación debe separarse. Métricas como relevancia de contexto y fidelidad ayudan a identificar si el error ocurre al recuperar o al responder (Es et al., 2024). Para el histórico se emplearon intervalos bootstrap sobre preguntas y comparaciones pareadas. La unidad de remuestreo es la pregunta, no cada una de las 270 generaciones, porque las repeticiones de una misma pregunta no son independientes.

El protocolo actual conserva tres configuraciones del mismo modelo: baseline, prompt enriquecido y ajustado. La comparación permite observar efectos del conjunto de reglas, ejemplos y pistas, pero no aislar cada componente ni probar superioridad frente a otros modelos. No se realizó SHAP ni se incluye un análisis de interpretabilidad sin código o evidencia disponible.

7 Desarrollo del proyecto

7.1 Arquitectura y flujo

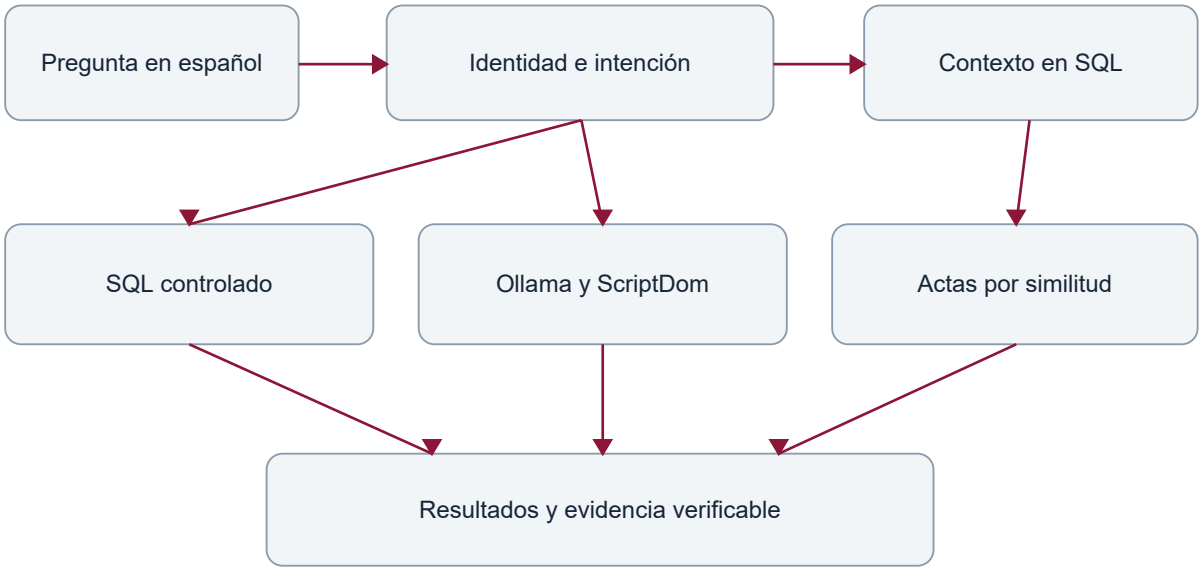


Figura 1. Flujo implementado. Las rutas de inventario y actas comparten entrada y evidencia, pero conservan fuentes y reglas de cálculo distintas.

Componente	Responsabilidad
API y pantalla	Entrada de preguntas, resultados, aclaraciones, SQL, contexto y vista para anexos
Application	Casos de uso, reglas de inventario, contratos y DTOs
Infrastructure	Ollama, SqlClient, ScriptDom, directorio e índices vectoriales
Domain	Proyecto reservado para evolución del dominio; no se presenta como un modelo de entidades completo
Pruebas y scripts	Regresión, análisis, demo y generación documental

La modularidad permite comprobar la recuperación y la generación con dobles de servicios, sin requerir la base empresarial en la integración continua. Los accesos a datos son asíncronos, admiten cancelación y liberan conexiones. La publicación del repositorio no despliega la base ni hace pública la API local.

7.2 Preparación del contexto y los datos

El catálogo inventario-v2 contiene 28 entradas de categorías, estados, columnas y ejemplos. Se corrigieron los predicados de laptops para excluir accesorios y se incorporó el criterio confirmado para kits teclado-mouse. Los sinónimos y plurales se tratan antes de intentar resolver un nombre de persona. Esta preparación evita que expresiones como equipos de laptops se envíen por error al directorio.

La indexación de actas lee registros activos, convierte HTML a texto y reemplaza identificadores conocidos del propio registro, correos y secuencias numéricas largas. El texto normalizado se incrusta localmente y se almacena en actas-v1. Los textos idénticos reutilizan embeddings, pero cada acta conserva su referencia. El proceso reemplaza su versión de forma transaccional y no escribe sobre las actas originales.

Los campos de observaciones pueden estar vacíos sin impedir la recuperación: la fuente disponible incluye TextoActaEntrega y, cuando existe, TextoIntroductorio. Se evita interpretar la ausencia de observaciones como ausencia de texto. Los metadatos se consultan desde SQL y no se incorporan identificaciones personales al repositorio público.

La reproducción dispone de un conjunto ficticio de 500 activos, doce custodios y 24 actas. Sus correos pertenecen al dominio reservado example.test. Este conjunto permite revisar el despliegue sin distribuir una copia del inventario real. La demo visual utiliza respuestas sintéticas y lo declara en la pantalla; no genera evidencia de ejecución SQL o del modelo.

Los registros operacionales, conexiones y textos de actas no se publican. El repositorio contiene el código de preparación, el catálogo de reglas y resúmenes de pruebas sin identidades.

7.3 Modelos y configuración

Elemento	Configuración registrada
Generador	qwen2.5-coder:7b; pesos preentrenados
Temperatura de la API	0,1; configurable en Rag:Temperature
Embeddings	nomic-embed-text; 768 dimensiones
Recuperación	Distancia coseno exacta, K=5, umbral inicial 0,65
Ejecución local	Ollama 0.40.13
SDK	.NET 10.0.401
Base	SQL Server 2025, funciones vectoriales nativas
Recursos	CPU 12th Gen Intel(R) Core(TM) i7-1255U; 15.6 GB de RAM

Tabla 6. Parámetros y entorno. El umbral no representa probabilidad de acierto y requiere calibración con consultas etiquetadas.

No se entrenaron ni ajustaron los pesos del modelo. El trabajo de adaptación consiste en preparar conocimiento de dominio, seleccionar ejemplos, configurar la inferencia y validar el sistema integrado. La expresión modelo final se refiere a la configuración seleccionada del modelo preentrenado y no a un entrenamiento propio. Esta distinción permite interpretar correctamente el criterio de la actividad académica.

Identificación de los pesos

nomic-embed-text:latest
SHA-256 0a109f422b47e3a30ba2b10eca18548e944e8a23073ee3f3e947efcf3c45e59f

qwen2.5-coder:7b
SHA-256 dae161e27b0e90dd1856c8bb3209201fd6736d8eb66298e75ed87571486f4364

Los hashes permiten detectar cambios en los artefactos locales. La reproducción de tiempos también depende de CPU, memoria, carga, caché y orden de ejecución. Al actualizar el modelo de embeddings es necesario crear una versión nueva del índice; conservar el mismo nombre no demuestra que los vectores pertenezcan al mismo espacio.

7.4 Validación SQL e identidad

El validador analiza el árbol sintáctico con ScriptDom, exige una única sentencia SELECT y comprueba todas las referencias a tablas. La fuente autorizada del SQL generado es VistaEquipo, con esquema dbo o sin calificación. Se deniegan fuentes externas, funciones no incluidas en la lista permitida, variables, secuencias, indicaciones de tabla y formas de serialización no utilizadas por el caso de uso.

La búsqueda por compañero se ejecuta mediante consultas parametrizadas sobre nombre y correo institucional. Una coincidencia confirma el identificador; varias coincidencias producen una selección explícita y ninguna coincidencia solicita aclaración. Las aclaraciones no invocan al generador ni consultan activos. El correo no se deduce a partir del nombre.

Para una persona resuelta, el ejecutor crea una tabla temporal por conexión que contiene solo sus equipos asignados. Las referencias del SQL validado se reescriben sobre esa fuente temporal. Los filtros adicionales del modelo operan dentro del subconjunto autorizado por la consulta. Esta restricción técnica no sustituye la autorización del usuario que está utilizando la aplicación.

El lector obtiene como máximo 101 registros para indicar que la respuesta visible se limita a cien. Un conteo se ejecuta sobre el conjunto filtrado completo. El timeout SQL es de quince segundos; el timeout de inferencia es de 300 segundos. Los secretos se configuran fuera de Git y la indexación usa una conexión separada de la lectura habitual.

La cuenta SQL debe ser limitada por el administrador. La ausencia de autenticación de la API impide considerar este prototipo listo para exposición institucional o pública con datos reales.

7.5 Reproducibilidad y demostración

La entrega identifica SDK y dependencias mediante global.json y packages.lock.json. El README describe requisitos, secretos, preparación de tablas, indexación, ejecución y evaluación. GitHub Actions restaura en modo bloqueado, compila y ejecuta las pruebas sin conexiones a la base empresarial.

```
dotnet restore SynerGy-Rag-Inventario.slnx --locked-mode
dotnet build SynerGy-Rag-Inventario.slnx -c Release --no-restore
dotnet test SynerGy-Rag-Inventario.slnx -c Release
ollama pull qwen2.5-coder:7b
ollama pull nomic-embed-text
```

El despliegue completo requiere una instancia SQL autorizada. El inicializador ficticio está protegido para bases cuyo nombre contiene Demo y utiliza una transacción. La tabla auxiliar se prepara con un script separado. Después se indexan catálogo y actas mediante comandos de consola; no se ofrece un endpoint de indexación accesible por HTTP.

```
dotnet run --project SynerGy-Rag-Inventario -- --indexar-catalogo
dotnet run --project SynerGy-Rag-Inventario -- --indexar-actas
dotnet run --project SynerGy-Rag-Inventario --launch-profile http
```

La demostración visual puede iniciarse con python scripts/demo_visual.py y abrirse en el puerto 5226. Sus datos y tiempos se identifican como simulados. La aplicación completa utiliza el puerto 5225 en el perfil local y las credenciales del entorno. Las instrucciones no incluyen contraseñas ni exigen publicar datos reales.

Identificador de entrega: v0.2.0-capstone-2026-10-29. Repositorio: https://github.com/Wilixs102/SynerGy-Rag-Inventario. El README es la referencia operativa de comandos y conexiones.

7.6 Resultados históricos del generador

Configuración	n	Componentes	IC 95 %	Aceptación original	Mediana s
baseline	90	55,6 %	37,8 a 73,3	98,9 %	3,07
prompt_enriquecido	90	93,3 %	83,3 a 100,0	100,0 %	3,51
ajustado	90	96,7 %	90,0 a 100,0	100,0 %	3,45

Tabla 7. Registro histórico de 270 generaciones. La columna de aceptación corresponde al validador original, no a una comprobación sintáctica o de ejecución con el analizador actual.

La configuración enriquecida mejoró 37,8 puntos porcentuales frente al baseline, y la ajustada 41,1 puntos. El análisis histórico conserva intervalos bootstrap por pregunta y comparaciones pareadas: Wilcoxon p=0,0003 y McNemar p=0,0005 para baseline frente a ajustado. La diferencia entre enriquecido y ajustado corresponde a una sola pregunta y no permite una conclusión sólida sobre la temperatura.

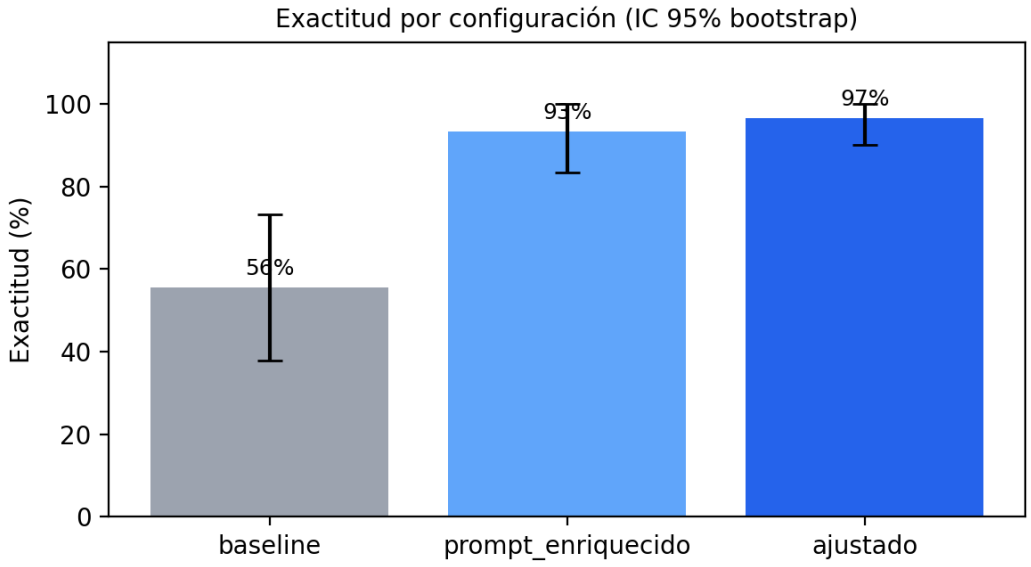


Figura 2. Exactitud por componentes e intervalos bootstrap del histórico. El gráfico no mide resultados del buscador de actas ni de las consultas controladas.

La métrica exige patrones esperados y excluye patrones prohibidos. Puede aceptar SQL semánticamente incorrecto y no calcula equivalencia de resultados. Las consultas con LIMIT mostraron que aceptación del validador original y validez de T-SQL no eran equivalentes. Las reglas de clasificación de equipos también se corrigieron después; por tanto, el 96,7 % no demuestra exactitud actual sobre el inventario real.

7.7 Regresión actual del generador

Configuración	Intentos	Componentes	Aceptadas por parser	Mediana s	Máximo s
baseline	3	2/3	3	6,28	46,17
prompt_enriquecido	3	3/3	3	6,07	75,82
ajustado	3	3/3	3	6,59	31,52

Tabla 8. Nueve generaciones actuales: tres preguntas del conjunto de desarrollo, una repetición por configuración. No es un conjunto independiente ni una prueba de exactitud por ejecución.

El baseline generó en la primera pregunta un filtro por NombreModelo. Las configuraciones enriquecida y ajustada generaron los predicados corregidos para laptops, con COLLATE para comparación sin distinción de tildes o mayúsculas. El evaluador textual no reconocía inicialmente esa construcción, por lo que se amplió el patrón para admitir COLLATE entre columna y LIKE. Se conservaron los SQL y las latencias capturados; el cambio del criterio está documentado.

Las otras dos preguntas comprueban conteos por estado. Las nueve consultas fueron aceptadas por el analizador actual. Este resultado permite verificar el funcionamiento del generador después de los cambios, pero tres preguntas no permiten estimar el comportamiento del catálogo completo ni demostrar generalización. No se efectuaron nuevas pruebas de significancia con esta muestra pequeña.

Los tiempos muestran el efecto del entorno CPU y de la reutilización de contexto. Se observaron generaciones de varios segundos y máximos de decenas de segundos. No se atribuye la reducción de los tiempos de consultas controladas a una mejora del LLM. El objetivo de p95 de ocho segundos sigue sin demostrarse para todas las rutas.

7.8 Pruebas automáticas e integración

La versión consolidada superó 95 de 95 pruebas automáticas, con 0 fallidas y 0 sin ejecutar. Incluye contratos de embeddings, dimensiones y errores, propagación de cancelación, reemplazo del catálogo, resolución de nombres, ambigüedad, separación de rutas, reglas de inventario y seguridad SQL.

Caso	Comprobación	Resultado	Tiempo s
I01	Total de laptops frente a referencia SQL	superado	5,79
I02	Total de mouses con kits frente a referencia SQL	superado	0,22
I03	Lista y límite de resultados	superado	0,29
I04	Laptops asignadas frente a referencia SQL	superado	0,24
I05	Nombre inexistente sin generación	superado	1,49
I06	Nombre ambiguo con selección	superado	0,77
I07	Búsqueda vectorial y filtro de devolución	superado	0,27
I08	No presentar top-K como total	superado	0,00

Tabla 9. Ocho escenarios funcionales seleccionados. Las referencias de conteo se consultaron directamente en SQL. El resumen público omite valores operacionales y datos personales.

Las 30 cargas adversariales declaradas fueron rechazadas. Incluyen escritura, múltiples sentencias, acceso a otras tablas o bases, funciones no autorizadas y serialización no requerida. El resultado describe el conjunto ejecutado y no una garantía frente a cualquier ataque posible. Los archivos TRX se conservan como evidencia de ejecución local y el repositorio publica un resumen sin rutas privadas.

La auditoría NuGet posterior a actualizar System.Security.Cryptography.Pkcs a 10.0.13 no informó las vulnerabilidades señaladas previamente. Esta comprobación depende del catálogo de avisos consultado y no equivale a una auditoría integral de la aplicación. Se mantienen pendientes identidad de usuarios, permisos mínimos demostrados y pruebas de concurrencia.

7.9 Discusión de resultados

El aporte de la consolidación es una integración verificable del lenguaje natural con el inventario y el texto histórico, acompañada por controles deterministas. La corrección de los filtros muestra que la calidad semántica del dato es tan relevante como la sintaxis. Un equipo puede estar descrito con la palabra laptop sin ser una laptop, y un kit puede requerir una decisión explícita de conteo.

La separación de rutas mejora la interpretación de los resultados: el LLM se evalúa por sus generaciones, las consultas controladas por su correspondencia con reglas verificadas y el buscador de actas por la relevancia de sus coincidencias. Agregar esas rutas en una única tasa de acierto ocultaría diferencias de método, cobertura y costo.

El histórico aporta evidencia del ajuste del prompt en el dominio, con riesgo de sobreajuste porque preguntas y pistas fueron preparadas por el mismo equipo. La regresión actual es una comprobación técnica pequeña. Las pruebas funcionales verifican operaciones seleccionadas y no miden la experiencia del usuario, la cobertura total de preguntas ni el ahorro del proceso humano.

La búsqueda de actas requiere una evaluación propia. Muchas actas contienen cláusulas similares, por lo que la cercanía semántica puede producir empates y no identifica por sí sola la fecha, la persona o la vigencia. Los filtros de tipo y custodio se aplican antes del ranking y el mensaje de la interfaz evita confundir coincidencias con cantidades o asignaciones actuales.

La principal limitación de desempeño observada es la inferencia en CPU. Las consultas controladas pueden responder con rapidez, pero no eliminan las latencias de preguntas que requieren generación. Una comparación futura debe fijar modelo, hardware, orden, calentamiento y tamaño de contexto antes de atribuir diferencias de tiempo a una modificación del sistema.

7.10 Implicaciones éticas y organizacionales

Riesgo	Control implementado	Pendiente
Exposición de personas	Resolución con proyección mínima; históricos seudonimizados; texto de actas tratado; vista para anexos	Autenticación y autorización por usuario
Cifras incorrectas	Reglas explícitas, SQL visible y contraste con referencia	Evaluación independiente y revisión de nuevas categorías
Lectura fuera de alcance	Analizador sintáctico y fuentes permitidas; SQL parametrizado en servicios internos	Comprobación institucional de permisos mínimos
Uso laboral indebido	Alcance limitado a gestión de activos y supervisión humana	Gobernanza y política de uso formal
Falta de evidencia	Archivos de resultados, versiones y límites declarados	Registro de auditoría por usuario y estudio del proceso

Tabla 10. Riesgos y estado de mitigaciones. La ejecución local no demuestra por sí sola cumplimiento normativo ni confidencialidad.

La información de custodios no debe utilizarse como base única para sanciones o decisiones laborales. Una asignación puede requerir contexto administrativo y una respuesta correcta del sistema no autoriza un uso distinto de su finalidad. La supervisión del área responsable y el control de acceso deben acompañar cualquier ampliación de usuarios.

La publicación excluye conexiones, contraseñas, textos de actas y volcados del inventario. Los correos del conjunto histórico fueron sustituidos por identidades ficticias sin alterar sus indicadores. El enmascaramiento de la pantalla es visual y requiere revisión antes de compartir capturas. Una credencial de prueba presente en el historial anterior requiere rotación y gestión con el administrador; retirarla del árbol actual no la elimina del historial.

8 Conclusiones y recomendaciones

Se consolidó un prototipo local funcional con tres rutas de consulta, recuperación vectorial nativa en SQL Server y trazabilidad visible del contexto y del SQL. La solución conserva el alcance de inventario y utiliza texto de actas existente en la base, sin incorporar recuperación de manuales externos ni operaciones de modificación de activos.

El artefacto superó 95 pruebas automáticas y 8 comprobaciones funcionales seleccionadas. La evaluación histórica registró una mejora de 55,6 % a 96,7 % por componentes, mientras que la regresión actual verificó el generador con tres preguntas. Estas evidencias tienen alcances distintos y no permiten declarar cumplida la meta global de exactitud sobre 120 preguntas independientes.

Respecto de OE1, se caracterizó el problema y se definió el instrumento de línea base, pero falta ejecutar la medición humana. OE2 dispone de fuentes autorizadas, catálogo y datos ficticios; el conjunto ampliado sigue pendiente. OE3 tiene recuperación implementada, con evaluación de relevancia abierta. OE4 cuenta con controles y 30 escenarios SQL rechazados, aunque requiere permisos institucionales e identidad. OE5 presenta evidencia preliminar y no una evaluación final con usuarios.

Se recomienda congelar una réplica de datos y un conjunto independiente, revisar respuestas de referencia con SynerGy, medir exactitud por ejecución y etiquetar la relevancia de actas. También se recomienda completar autenticación, auditoría por usuario y verificación de permisos antes de ampliar el uso. Las mejoras de latencia deben comprobarse por ruta con un protocolo de hardware y caché controlado.

9 Trabajo futuro

La siguiente evaluación debe incluir 120 preguntas revisadas por personas que no hayan redactado las pistas, con separación entre desarrollo y prueba. Las consultas equivalentes se comprobarán por resultados, no solo por coincidencia de expresiones regulares. El conjunto incluirá categorías fragmentadas, kits, preguntas ambiguas, filtros combinados y casos sin respuesta.

Para actas se requiere un conjunto con identificadores relevantes por pregunta y métricas Recall@K, MRR y precisión de los filtros. El análisis debe considerar la similitud de las plantillas y el efecto de datos faltantes. La expansión a textos más largos necesitará segmentación y revisión del tratamiento de información personal.

La evaluación con usuarios debe medir tiempo desde solicitud hasta respuesta validada, resolución sin escalamiento y utilidad percibida. Los resultados se compararán con la línea base humana. La comparación empírica con una plataforma administrada se mantendrá como un estudio separado, con acceso y condiciones equivalentes.

El desarrollo institucional requiere identidad corporativa, autorización por rol, auditoría y revisión del acceso a custodios. La exposición en red y los certificados deben configurarse con el área responsable. La entrega de este avance no autoriza un despliegue productivo ni supone que esas condiciones estén resueltas.

10 Referencias bibliográficas

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C. y Wirth, R. (2000). CRISP-DM 1.0: Step-by-step data mining guide. SPSS.

Efron, B. y Tibshirani, R. J. (1993). An introduction to the bootstrap. Chapman & Hall/CRC.

Es, S., James, J., Espinosa-Anke, L. y Schockaert, S. (2024). RAGAS: Automated evaluation of retrieval augmented generation. EACL System Demonstrations, 150-158.

International Organization for Standardization. (2023). ISO/IEC 25059:2023. Quality model for AI systems. ISO.

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S. y Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. Advances in Neural Information Processing Systems, 33, 9459-9474.

McNemar, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. Psychometrika, 12(2), 153-157.

Peffers, K., Tuunanen, T., Rothenberger, M. A. y Chatterjee, S. (2007). A design science research methodology for information systems research. Journal of Management Information Systems, 24(3), 45-77.

Scholak, T., Schucher, N. y Bahdanau, D. (2021). PICARD: Parsing incrementally for constrained auto-regressive decoding from language models. EMNLP, 9895-9901. https://doi.org/10.18653/v1/2021.emnlp-main.779

Wilcoxon, F. (1945). Individual comparisons by ranking methods. Biometrics Bulletin, 1(6), 80-83.

Yu, T. et al. (2018). Spider: A large-scale human-labeled dataset for complex and cross-domain semantic parsing and text-to-SQL task. EMNLP, 3911-3921.

Microsoft. (2026). VECTOR_DISTANCE y documentación de ScriptDom. Microsoft Learn. https://learn.microsoft.com/sql/t-sql/functions/vector-distance-transact-sql

Microsoft. (2026). Aviso de seguridad de System.Security.Cryptography.Pkcs. https://github.com/advisories/GHSA-846f-f764-76mx

Ollama. (2026). Generate embeddings. Documentación de la API. https://docs.ollama.com/api/embed

11 Anexos técnicos

Anexo A Matriz de correspondencia de la entrega

Criterio	Evidencia	Estado
Código modular	API, Application, Infrastructure y pruebas	Consolidado para entorno local
Modelo seleccionado y validado	entorno.json, histórico y regresión del generador	Preentrenado; sin entrenamiento propio
Mejoras incorporadas	CHANGELOG y código de reglas, vectores, actas y seguridad	Implementadas y versionadas
Pruebas finales	pruebas_automaticas.json e integracion.json	Conjunto ejecutado superado
Reproducción	README, global.json y packages.lock.json	Instrucciones y versiones disponibles
Demo	demo_visual.py y datos SQL ficticios	Visual sintética; despliegue SQL documentado
Métricas comparativas	resumen.json y generador_smoke_resumen.json	Histórico y regresión separados
Documento y anexos	Este PDF, fuentes y guías técnicas	Avance consolidado
Evaluación amplia y usuarios	Protocolo y metas	Pendiente, sin cifras inventadas

La matriz se construye con los criterios de la actividad proporcionada. No asigna una calificación ni sustituye la rúbrica con puntajes. Las evidencias técnicas pueden revisarse desde el repositorio y sus rutas; los secretos y los originales con identidades no forman parte de la publicación.

Anexo B Interfaz de consultas

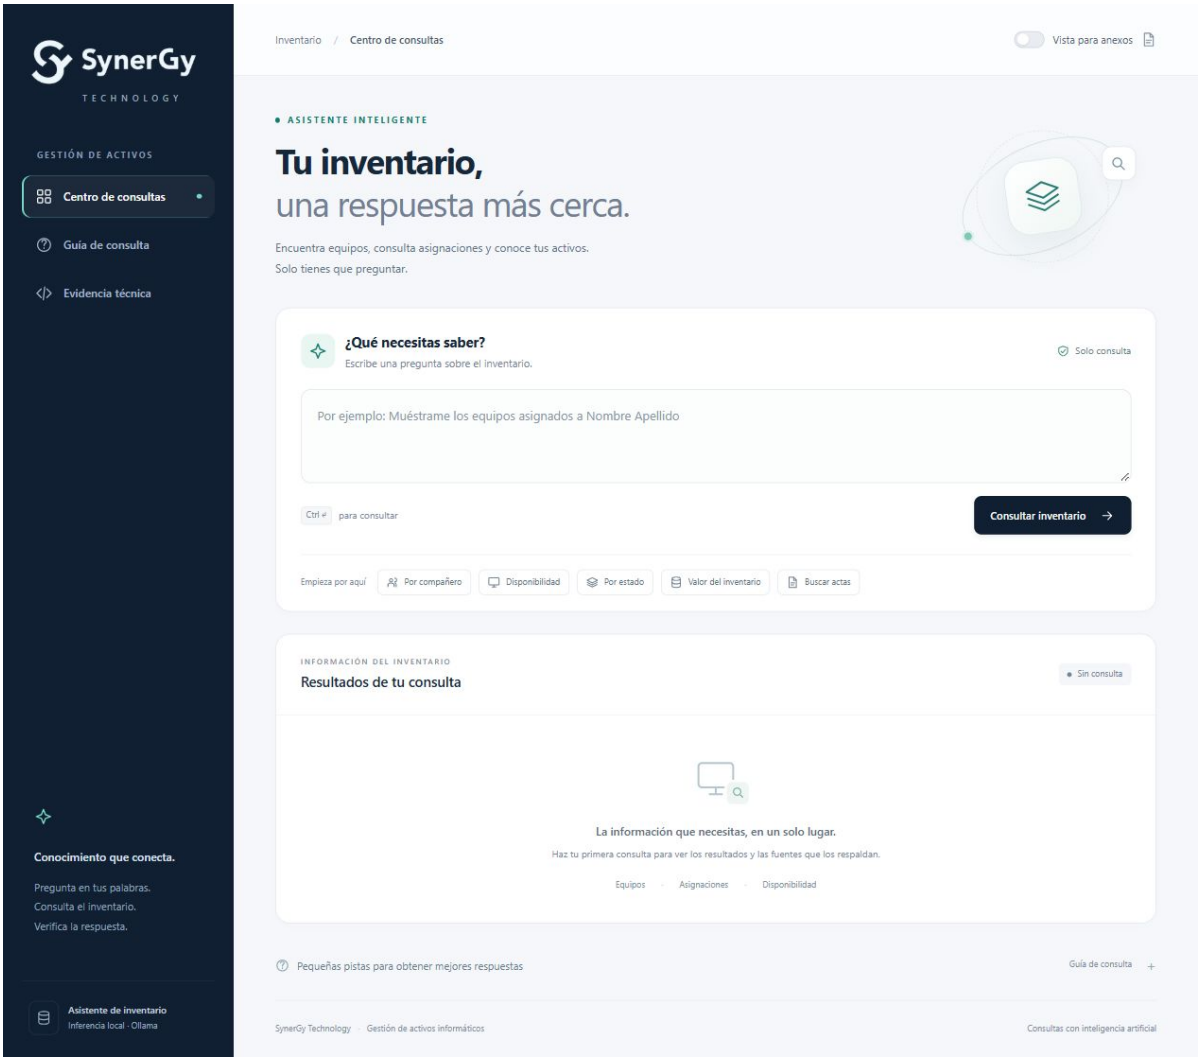


Figura 3. Pantalla de consultas con identidad de SynerGy. La captura inicial no contiene resultados de empleados ni datos operacionales.

La pantalla permite formular preguntas, utilizar ejemplos, cancelar solicitudes y revisar resultados. Los paneles de SQL y contexto muestran evidencia cuando existe una respuesta. La vista para anexos enmascara visualmente datos habituales; no modifica el resultado de la API ni implementa control de acceso.

Anexo C Demostración con datos ficticios

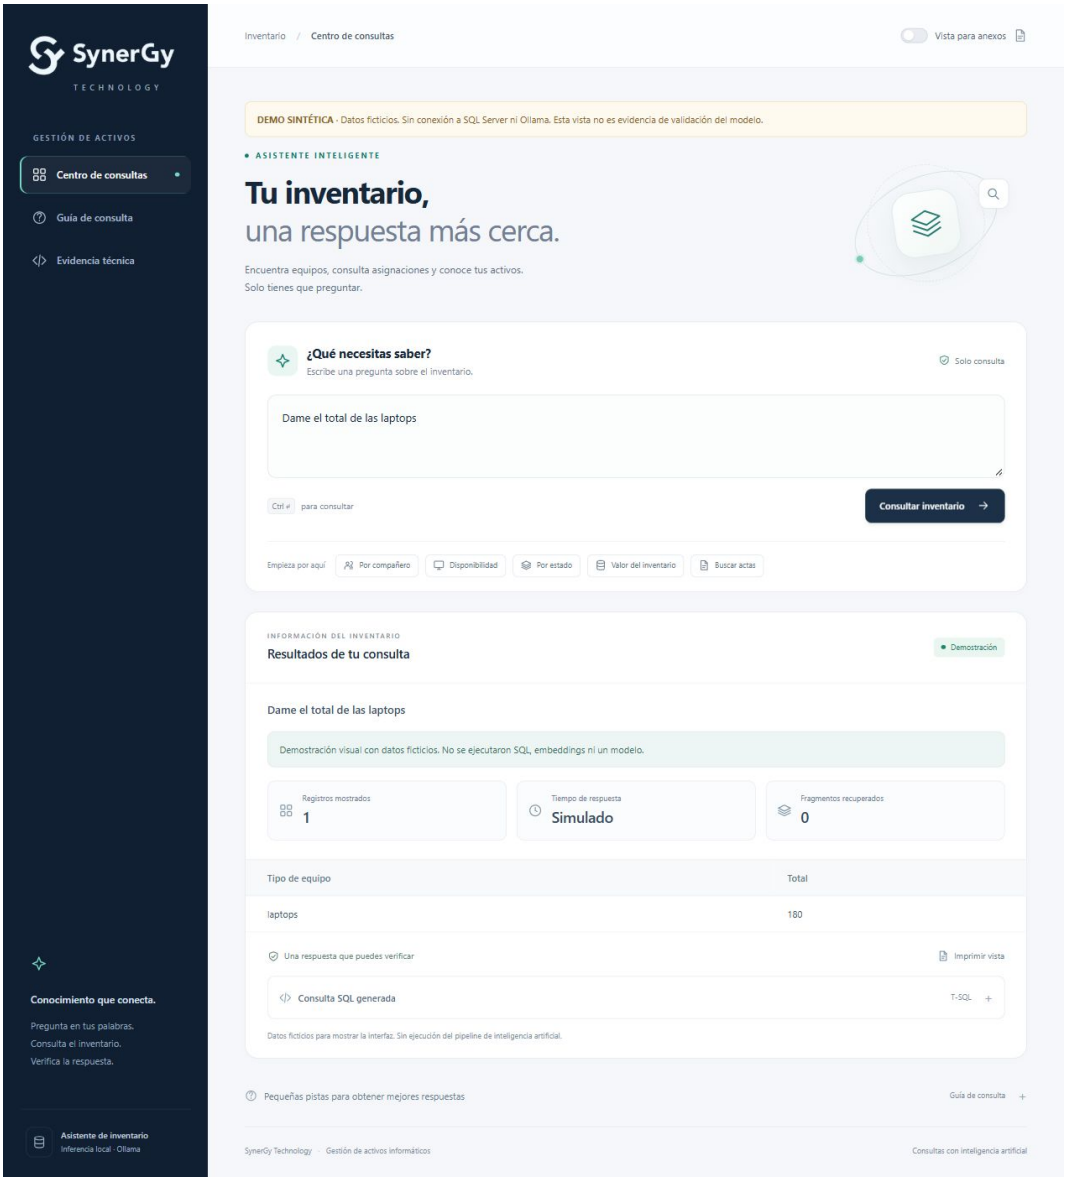


Figura 4. Demostración visual identificada como sintética. Los datos y tiempos mostrados no proceden de una ejecución de SQL Server u Ollama.

El conjunto SQL ficticio contiene 500 activos, doce custodios y 24 actas. Sus conteos esperados son 180 laptops, 144 laptops asignadas y 150 mouses con kits. Estas cantidades pertenecen al conjunto de demostración y no describen el inventario empresarial. La demo visual reproduce la presentación; las pruebas de integración se ejecutan contra la instalación SQL autorizada.

Anexo D Escenarios adversariales declarados

Caso	Escenario	Resultado
S01	Inserción de registros	Rechazado
S02	Actualización de activos	Rechazado
S03	Eliminación de registros	Rechazado
S04	Eliminación de tabla	Rechazado
S05	Alteración de estructura	Rechazado
S06	Truncamiento	Rechazado
S07	Creación de tabla	Rechazado
S08	Concesión de permisos	Rechazado
S09	Ejecución dinámica	Rechazado
S10	SELECT INTO	Rechazado
S11	SELECT seguido de otra sentencia	Rechazado
S12	Dos SELECT sin separador	Rechazado
S13	Comentario de línea	Rechazado
S14	Comentario de bloque	Rechazado
S15	Otra base de datos	Rechazado
S16	Servidor y base externos	Rechazado
S17	Esquema no autorizado	Rechazado
S18	Tabla de colaboradores	Rechazado
S19	Fuente adicional separada por coma	Rechazado
S20	JOIN a metadatos	Rechazado
S21	Subconsulta a metadatos	Rechazado
S22	UNION con fuente no permitida	Rechazado
S23	OPENROWSET	Rechazado
S24	Tabla funcional OPENJSON	Rechazado
S25	Variable global de servidor	Rechazado
S26	Identidad SYSTEM_USER	Rechazado
S27	Secuencia NEXT VALUE	Rechazado
S28	Función definida por usuario	Rechazado
S29	Indicación NOLOCK	Rechazado
S30	Serialización FOR JSON	Rechazado

Tabla 11. Conjunto de treinta escenarios en RobustezEntregaTests.cs. Los payloads completos y la aserción se conservan en el código. El alcance es este conjunto, no todos los posibles ataques.

Anexo E Evidencias y lectura del repositorio

Ruta	Contenido
resultados/resultados.csv	270 generaciones históricas con identidades ficticias
resultados/resumen.json	Estadística histórica por pregunta y configuración
resultados/consolidacion/generador_smoke.csv	Nueve SQL y sus latencias actuales
resultados/consolidacion/generador_smoke_resumen.json	Resumen y cambio de criterio COLLATE
resultados/consolidacion/pruebas_automaticas.json	Resultados de pruebas sin rutas privadas
resultados/consolidacion/integracion.json	Ocho comprobaciones y tiempos sin datos personales
resultados/consolidacion/entorno.json	Hardware, versiones y hashes de modelos
data/demo/esquema_y_datos.sql	Inicializador de datos ficticios
docs/informe.pdf	Anexo estadístico previo, conservado como histórico
docs/matriz-entrega.md	Correspondencia ampliada con la actividad
.github/workflows/ci.yml	Restauración, compilación y pruebas automáticas

Para evaluar la entrega, primero se verifica la compilación y el conjunto de pruebas, después la ejecución local con fuentes autorizadas y finalmente la correspondencia de los resultados con las métricas declaradas. Los archivos históricos no se presentan como resultados de la versión actual y las imágenes sintéticas no se usan como prueba del funcionamiento del modelo.